

UNIVERSITÀ DEGLI STUDI DI MILANO - BICOCCA

LM IN SCIENZE STATISTICHE ED ECONOMICHE CLAMSES

MACHINE LEARNING PROJECT

A Recommender System for restaurants

Authors

BAGNATI ELENA MATR. 792045,
CARONTE MARTINA MATR. 789451,
SISTI SARA MATR. 789909

Gennaio 2018

Abstract – Un Recommender System (RS) è un sistema il cui obiettivo è predire il “rating” o le preferenze di un utente per un prodotto o servizio. In particolare il sistema cerca di consigliare ad ogni utente un oggetto che potrebbe potenzialmente piacergli.

I nostri dati consistono in: dati strutturati riguardanti 130 ristoranti e 138 utenti, 1161 ratings multidimensionali. Ogni utente, infatti, ha dato sia una valutazione generale del ristorante, sia due valutazioni specifiche riguardanti cibo e servizio (le valutazioni hanno range 0-2). L’obiettivo di questa analisi è la realizzazione di un RS che suggerisca 10 ristoranti ad ogni utente sulla base delle sue preferenze precedenti.

Per prima cosa è stata realizzata un’analisi di tipo esplorativo dei dati riguardanti utenti e ristoranti e in seguito sono stati confrontati diversi algoritmi di recommender system standard. Infine è stata implementata una tecnica di RS multidimensionale.

1 Introduzione

Un recommender system è un sistema che cerca di cogliere le preferenze di consumatori individuali e consiglia prodotti in base ad esse. Lo scopo di un sistema di questo tipo è il miglioramento della qualità delle decisioni di un consumatore che cerca e sceglie prodotti online.¹ Le raccomandazioni di un RS possono essere basate su:

- “content based filtering”, cioè basandosi sugli attributi dei prodotti e consigliando prodotti simili a quelli già valutati positivamente dall’utente;
- “collaborative filtering”, cioè basando le raccomandazioni per un utente sulle scelte di altri soggetti a lui simili in base ai prodotti valutati precedentemente;
- “knowledge filtering”, cioè costruendo raccomandazioni considerando le richieste del

consumatore sul prodotto e gli attributi del prodotto stesso.

L’obiettivo di questo progetto è la realizzazione di un recommender system costruito basandosi sul principio di “collaborative filtering”, poichè si tratta di un approccio noto, con molte varianti e possibilità, applicabile in molti domini. Il nostro caso di studio è la costruzione di un RS che consigli 10 ristoranti agli utenti di cui sono note le precedenti valutazioni.

1.1 Datasets

I dataset che sono stati utilizzati per le analisi sono stati creati dal “Department of computer science - National center of research and technological development CENIDET, Mexico”. Sono stati reperiti dalla piattaforma Kaggle [1] e consistono in: 4 files contenenti dati strutturati relativi a varie caratteristiche dei ristoranti (metodi di pagamento accettati, tipo di cucina, localizzazione, presenza di parcheggio, orari di apertura, ..); 3 files contenenti dati strutturati relativi a varie caratteristiche degli utenti (tipo di cucina preferito, localizzazione, metodi di pagamento, preferenze riguardo ambienti frequentati, status familiare, ..); 1 file contenente ratings utente-ristorante multidimensionali (overall ratings, ratings per il cibo e per il servizio), il cui range è 0-2.

Per poter procedere nello studio sono stati uniti i files riguardanti utenti e quelli riguardanti ristoranti in due dataset unici.

Per quanto riguarda i ratings: abbiamo un totale di 1161 valutazioni effettuate da 138 utenti per 130 ristoranti.

| | |
|-------------------------------|-----------|
| # of items | 130 |
| Minimum # of ratings per item | 3 |
| Average # of ratings per item | 8.930769 |
| Maximum # of ratings per item | 36 |
| # of users | 138 |
| Minimum # of ratings per user | 3 |
| Average # of ratings per user | 8.413043 |
| Maximum # of ratings per user | 18 |
| # of ratings | 1161 |
| Average rating | 2.199828 |
| Sparsity | 0.9352843 |

C’è una sparsità del 94% circa: ciò potrebbe creare delle difficoltà nell’efficacia delle predizioni del RS.

¹[Xiao e Benbasat, MISQ, 2007]

Le valutazioni generiche (ratings overall) sono distribuite sul loro range come in Figura 1. Mentre in Figura 2 possiamo notare come si distribuisce il numero di ratings nei ristoranti: solamente circa 30 ristoranti hanno ricevuto più di 10 ratings, tutti gli altri sono stati valutati un minor numero di volte.




Figura 1: Istogramma frequenze ratings.




Figura 2: Frequenza di ratings per item.

2 Data Exploration

In questa sezione verranno descritte le analisi esplorative sui dati strutturati e sui ratings multidimensionali, svolte al fine di cogliere

maggiori informazioni sui dati e capire come trattarli.

2.1 Clusters per coordinate spaziali

Per prima cosa, analizzando le informazioni strutturate che abbiamo a disposizione, è emerso che sia per utenti che per ristoranti esistono tre cluster determinati naturalmente dalle loro coordinate spaziali (Figure 3-4).

In generale, gran parte delle valutazioni so-

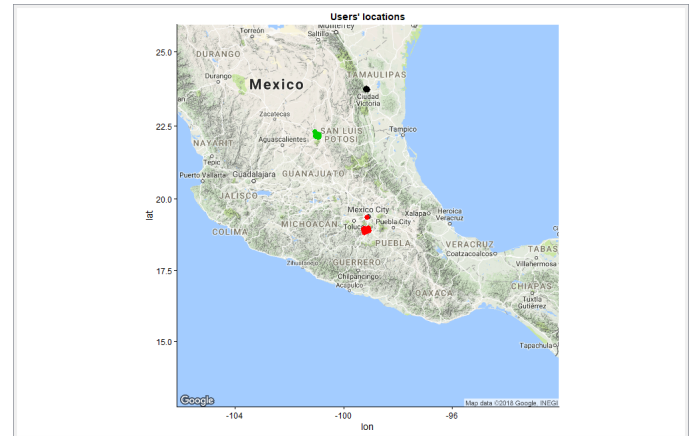


Figura 3: Cluster degli utenti dati dalle coordinate spaziali.



Figura 4: Cluster dei ristoranti dati dalle coordinate spaziali.

no state inserite da utenti per ristoranti situati nella loro stessa zona di appartenenza. Ci sono però 64 ratings di utenti provenienti dalle

zone in rosso e nero per ristoranti della zona in verde (nelle Figure 3-4): queste valutazioni sono state date da un totale di 6 utenti che hanno recensito locali che si trovano prevalentemente nella città di Ciudad Victoria, capitale dello stato Tamaulipas, e nella città di San Luis Potosi. Questi ristoranti hanno tutti una fascia di prezzo medio/bassa e ambiente informale/casual, si è quindi ipotizzato che la zona sia di interesse turistico.

Questa considerazione è rilevante per la costruzione di un recommender system basato su “content based filtering”, nel caso invece di RS basato su “collaborative filtering” o “knowledge filtering” invece gli algoritmi apprendono automaticamente le relazioni tra utenti e ristoranti utilizzando misure di similarità. Nel nostro caso, quindi, il risultato di questa analisi è fine alla semplice esplorazione dei dati.

2.2 Relative importance of quality domains

Lo scopo di questa analisi è l’identificazione di relazioni empiriche tra il rating generico e quelli relativi a specifici fattori di qualità (cibo e servizio): ciò è stato fatto attraverso lo studio delle loro relazioni lineari. Tramite l’utilizzo di una semplice regressione lineare è stato stimato il seguente modello:

$$rat_overall = 0.54*rat_food + 0.44*rat_service \quad (1)$$

I coefficienti della regressione sono significativi e emerge che sia il rating relativo al cibo sia quello relativo al servizio impattano sul rating generico. In particolare il cibo sembra influenzare maggiormente il giudizio complessivo degli utenti. L’Adjusted R^2 è pari a 0.85: le variabili spiegano gran parte della variabilità del rating generico.

Ripetendo l’analisi in modo stratificato rispetto alle variabili strutturate che abbiamo a disposizione riguardo gli utenti, si è notato che l’unica stratificazione da cui emergono gruppi eterogenei è quella realizzata secondo la variabile “ambience” (attributo nominale con tre modalità: “family”, “friends”, “solitary”; descrive la compagnia con cui l’utente visita i ristoranti). Per utenti che tendenzialmente

| | Family | Friends | Solitary |
|--------------------|--------|---------|----------|
| Coeff. rat_food | 0.52 | 0.59 | 0.42 |
| Coeff. rat_service | 0.45 | 0.4 | 0.54 |

Tabella 1: Coefficienti di regressione per livelli di “ambience”.

visitano ristoranti da soli la variabile più importante per la determinazione del rating overall è il servizio.

2.3 Penalty-Reward Contrast Analysis

Un altro modo per determinare la rilevanza dei fattori di qualità sulla soddisfazione della clientela è la penalty-reward contrast analysis. La soddisfazione del consumatore può essere infatti valutata anche attraverso una struttura a tre fattori [2]. Secondo questo modello gli attributi qualitativi possono essere raggruppati in tre categorie, ognuna delle quali esercita un impatto differente sulla soddisfazione del consumatore:

- i “basic factors” sono i requisiti minimi che causano l’insoddisfazione se non sono realizzati, hanno impatto maggiore sulla valutazione finale se sono valutati negativamente piuttosto che positivamente;
- gli “excitement factors” sono fattori che aumentano la soddisfazione del consumatore se realizzati ma non causano malcontento in caso contrario, performance positive di questi fattori hanno quindi maggior impatto sul rating generico rispetto a performance negative;
- i “performance factors” portano soddisfazione se la performance è alta e insoddisfazione se la performance è bassa, in questo caso l’impatto sulla valutazione finale è lo stesso se sono valutati negativamente o positivamente.

Per decifrare la struttura dei fattori riguardo il gradimento degli utenti si utilizza la “Penalty-

reward contrast analysis” [3]: si creano due variabili dummy per ogni fattore di qualità (cibo e servizio nel nostro caso di studio), la prima dummy (“basic factor”) vale 1 quando il fattore in considerazione è stato valutato negativamente (nel nostro caso quando gli è stato attribuito rating 0), la seconda (“excitement factor”) vale 1 quando il fattore è stato invece valutato positivamente (quando gli è stato attribuito rating 2). Infine si valutano le influenze delle suddette dummy con un modello di regressione lineare: i coefficienti stimati relativi alle dummy “basic factor” corrispondono alle penalty, cioè l’impatto sul rating complessivo di una valutazione negativa del fattore di qualità, quelli invece relativi alle dummy “excitement factor” corrispondono ai reward, cioè l’influenza sul rating complessivo di una valutazione positiva del fattore di qualità.

Dai risultati dell’analisi (in Figura 5) emerge

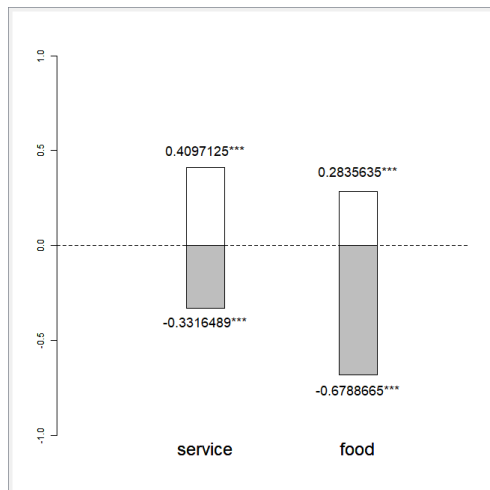


Figura 5: PR contrast analysis for food and service quality factors.

che il fattore cibo è un “basic factor”, in quanto pesa maggiormente quando valutato negativamente (penalty= -0.33) piuttosto che quando valutato positivamente (reward= 0.41), mentre il fattore servizio è un “excitement factor”, poichè impatta di più quando le sue performance sono positive (reward= 0.28) rispetto che negative (penalty= -0.68).

3 Standard Recommender System

In questa sezione saranno descritte diverse tecniche di “collaborative filtering” RS che si basano solamente sul rating overall (generico), ai fini di questa analisi non sono necessari nè utili i dati riguardanti informazioni strutturate e ratings di cibo e servizio. Per prima cosa, applicando diversi algoritmi si utilizzeranno le valutazioni generiche attribuite ai ristoranti dagli utenti al fine di predire i rating per ristoranti non ancora valutati per ogni utente.

Gli algoritmi [4] che sono stati utilizzati per calcolare i rating previsti a partire dai dati a disposizione sono:

- **Global Average** che utilizza la media complessiva di tutti i rating per fare predizioni;
- **Item Average** che utilizza la media dei rating per oggetto (in questo caso ristorante) per fare predizioni;
- **User Average** che utilizza la media dei rating per utente per fare predizioni;
- **User based KNN** che, determinata una certa misura di similarità (coseno) e dati un utente U1 e un ristorante R1 che U1 ancora non ha valutato, trova i K utenti più simili ad U1 (rispetto alle valutazioni attribuite precedentemente e alla misura scelta) che abbiano valutato il ristorante R1 e calcola il rating predetto come combinazione delle valutazioni che i K utenti hanno attribuito ad R1 pesate per la similarità dei K utenti a U1;
- **Item based KNN** che, determinata una certa misura di similarità (coseno) e dati un ristorante R1 e un utente U1 che non ha ancora valutato R1, trova i K ristoranti più simili ad R1 (rispetto alle valutazioni che sono state attribuite precedentemente e alla misura scelta) che siano stati valutati da U1 e calcola il rating predetto come combinazione delle valutazioni che i K ristoranti hanno ottenuto da U1 pesate per la similarità dei K ristoranti a R1;

- **Funk SVD** implementa una tecnica di ottimizzazione (gradient-descent stocastico) per calcolare le matrici di fattorizzazione per utenti e ristoranti U e V (come in una decomposizione a valori singolari): considerando R come matrice dei rating predetti, risulta $R = UV^T$.

Per implementare le tecniche appena descritte abbiamo utilizzato il package **rrecsys** [5], implementato per il linguaggio di programmazione R.

Dopo aver calcolato le previsioni dei ratings, viene generata una lista di N ($N=10$ nel nostro caso) items che potrebbero potenzialmente piacere all'utente (raccomandazioni). Ciò è svolto utilizzando nuovamente il package **rrecsys**, che fornisce per tutti gli algoritmi sopracitati il metodo di generazione di raccomandazioni ;“hpr”, che suggerisce ad ogni utente gli N items il cui rating predetto è maggiore. Per gli algoritmi UBKNN e IBKNN il package fornisce un ulteriore metodo di generazione chiamato “mf”, che invece suggerisce gli items più frequenti nelle vicinanze dell'utente (dove per vicinanza si intendono i K utenti/ristoranti con similarità maggiore).

Gli algoritmi sono stati valutati tramite una 5 fold cross validation² e sono stati confrontati tramite:

- due misure che riguardano l'accuratezza dei ratings predetti, ovvero *MAE* (*mean absolute error*) e *RMSE* (*root mean squared error*), che valutano la differenza tra i rating predetti e quelli effettivamente attribuiti dagli utenti nel test set.
- due misure che riguardano la bontà delle raccomandazioni, cioè: *Precision* valutata come proporzione di oggetti raccomandati che sono realmente buoni per l'utente (cioè che l'utente ha valutato positivamente nel test set); *Recall* valutata come proporzione di items rilevanti raccomandati rispetto alla totalità di

items rilevanti (cioè quelli che nel test set risultano valutati positivamente).

| | MAE | RMSE | PREC | REC |
|----------|-------|-------|-------|-------|
| golbalAV | 0.664 | 0.690 | 0.007 | 0.273 |
| itemAV | 0.713 | 0.749 | 0.009 | 0.274 |
| userAV | 0.462 | 0.487 | 0.007 | 0.273 |
| KNNIBmf | 0.684 | 0.722 | 0.059 | 0.589 |
| KNNIBhpr | 0.684 | 0.722 | 0.011 | 0.284 |
| KNNUBmf | 0.462 | 0.487 | 0.043 | 0.468 |
| KNNUBhpr | 0.462 | 0.487 | 0.038 | 0.456 |
| FunkSVD | 1.166 | 1.213 | 0.007 | 0.273 |

Tabella 2: Evaluation for overall ratings RS algorithms.

Nel nostro caso di studio, MAE e RMSE non sono misure affidabili dell'accuratezza delle previsioni. Infatti, essendo il range dei ratings molto ristretto (0-2), l'errore di previsione sembra sempre essere molto basso. Per quanto riguarda l'accuratezza della predizione dei rating, gli algoritmi che ottengono valori più bassi di MAE e RMSE sono **User Average, User based KNN** (con tecniche di raccomandazione “mf” o “hpr”, le predizioni dei rating sono le stesse). Per quanto concerne invece la Precision e Recall delle raccomandazioni gli algoritmi che ottengono migliori performance sono **Item based KNN** e **User based KNN**, entrambe con tecnica di raccomandazione “mf”.

La Precision dei recommender systems risulta comunque molto bassa: ciò è dovuto alla sparsità molto elevata dei dati (che ricordiamo, è pari al 94%). Il problema della sparsità potrebbe essere aggirato selezionando una porzione del dataset più “densa”, cioè con utenti e ristoranti con molte valutazioni, ma i dati non sarebbero sufficienti per le analisi.

4 Multi-rating collaborative filtering RS

Dopo aver valutato gli algoritmi RS utilizzando soltanto il rating overall per fare predizioni

²Sono stati scelti 5 folds poichè aumentandone il numero l'analisi sarebbe risultata computazionalmente onerosa.

e raccomandazioni, in questa sezione verranno descritti i passaggi seguiti per l'implementazione di un sistema di raccomandazione che tenga in considerazione i ratings multidimensionali (multi-rating), cioè le valutazioni dei fattori di qualità cibo e servizio.

Per integrare le valutazioni multidimensionali in un sistema di raccomandazione, è stato seguito il criterio **“aggregation-function based approach”** [6] che consiste in due fasi:

- 1- Per prima cosa si considera il problema di predire i ratings per ogni fattore di qualità singolarmente, tramite l'utilizzo di un “collaborative filtering” recommender system standard.
- 2- Deve essere scelta una funzione di aggregazione che combini i ratings predetti di ogni fattore di qualità al fine di generare predizioni per il rating generico.

Nella nostra analisi abbiamo solamente due fattori di qualità: cibo e servizio. Per entrambi abbiamo utilizzato, al fine di ottenere le previsioni dei ratings, un algoritmo di “collaborative filtering” di tipo **User based KNN**, poichè abbiamo confrontato le stesse tecniche presentate nella sezione 3 per i due fattori ed è risultata essere la tecnica migliore (come mostrato nelle tabelle 3 e 4) quando le raccomandazioni vengono fatte con metodo “hpr”, cioè il metodo che verrà applicato per fare raccomandazioni in questa analisi.

In seguito, è stata scelta come funzione di aggregazione il modello di regressione lineare multipla

$$rat_overall = \beta_0 u * rat_food + \beta_1 u * rat_service$$

della quale sono stati stimati i coefficienti di regressione per ogni utente, così da considerare l'influenza che i fattori di qualità cibo e servizio hanno sul rating generico dei ristoranti per ciascun utente.

A questo punto si è deciso di normalizzare i coefficienti di regressione in modo che la loro somma sia pari a 1. Infatti, dato che l'obiettivo finale è ottenere la previsione del rating overall come aggregazione dei rating predetti

di cibo e servizio pesati per la loro importanza per ogni utente, se la somma fosse diversa da 1 la predizione del rating overall potrebbe andare fuori range (0-2). Durante questa fase sono state inoltre riscontrate alcune problematiche:

- per alcuni utenti viene stimato solamente un coefficiente di regressione, mentre l'altro risulta mancante. Osservando i dati è emerso che ciò accade poichè le esplicative della regressione risultano perfettamente multicollineari: in questo caso l'utente attribuisce lo stesso peso alla qualità di cibo e servizio, abbiamo quindi corretto i “beta” attribuendo ad entrambi il valore di 0.5.
- per altri utenti uno dei due coefficienti di regressione risulta negativo, il che non è ragionevole: sembrerebbe che a parità delle altre condizioni, un aumento della valutazione di un fattore di qualità comporti una riduzione nel rating complessivo. Ciò accade poichè probabilmente l'utente considera nella valutazione complessiva altri fattori di cui non siamo a conoscenza che quindi, in questi casi, falsano il risultato: il rating complessivo risulta contraddittorio rispetto ai rating specifici di cibo e servizio. In questo caso è stato deciso di correggere il “beta” negativo con il valore di 0 e quello positivo con il valore di 1. Di seguito un esempio:

| Utente | Rist | rat_overall | rat_food | rat_service |
|--------|--------|-------------|----------|-------------|
| U1038 | 132854 | 1 | 2 | 2 |
| U1038 | 132856 | 0 | 1 | 1 |
| U1038 | 132858 | 0 | 2 | 1 |

- infine, per altri utenti i coefficienti della regressione risultano entrambi pari a zero, ciò accade poichè esistono users che hanno inserito solamente valutazioni nulle. Anche in questo caso i “beta” sono stati corretti attribuendo ad entrambi il valore di 0.5, poichè l'utente è indifferente. Di seguito un esempio:

| Utente | Rist | rat_overall | rat_food | rat_service |
|--------|--------|-------------|----------|-------------|
| U1031 | 132663 | 0 | 0 | 0 |
| U1031 | 132665 | 0 | 0 | 0 |
| U1031 | 132668 | 0 | 0 | 0 |

| | MAE | RMSE | PREC | REC |
|----------|-------|-------|-------|-------|
| golbalAV | 0.680 | 0.704 | 0.007 | 0.258 |
| itemAV | 0.699 | 0.735 | 0.007 | 0.260 |
| userAV | 0.520 | 0.553 | 0.007 | 0.258 |
| KNNIBmf | 0.696 | 0.736 | 0.057 | 0.578 |
| KNNIBhpr | 0.696 | 0.736 | 0.012 | 0.290 |
| KNNUBmf | 0.520 | 0.553 | 0.044 | 0.467 |
| KNNUBhpr | 0.520 | 0.553 | 0.038 | 0.448 |
| FunkSVD | 1.150 | 1.214 | 0.007 | 0.258 |

Tabella 3: Evaluation for food ratings RS algorithms.

| | MAE | RMSE | PREC | REC |
|----------|-------|-------|-------|-------|
| golbalAV | 0.639 | 0.682 | 0.006 | 0.282 |
| itemAV | 0.676 | 0.721 | 0.010 | 0.299 |
| userAV | 0.498 | 0.535 | 0.006 | 0.282 |
| KNNIBmf | 0.662 | 0.709 | 0.055 | 0.592 |
| KNNIBhpr | 0.662 | 0.709 | 0.012 | 0.305 |
| KNNUBmf | 0.502 | 0.539 | 0.042 | 0.488 |
| KNNUBhpr | 0.502 | 0.539 | 0.033 | 0.448 |
| FunkSVD | 1.039 | 1.111 | 0.006 | 0.282 |

Tabella 4: Evaluation for service ratings RS algorithms.

Dopodichè abbiamo predetto, aggregando i rating predetti di cibo e servizio coi pesi stimati dalla regressione lineare per ogni utente, il rating complessivo

$$rat_{overall} = \hat{\beta}_0 u * rat_food + \hat{\beta}_1 u * rat_service$$

e infine abbiamo selezionato per ogni utente i 10 ristoranti con rating complessivo maggiore come raccomandazione.

Di nuovo, per testare le performance del metodo appena descritto (i cui risultati sono in Tabella 5), il tutto è stato replicato utilizzando la ripartizione in 5 folds (in particolare, per rendere i risultati confrontabili con quelli ottenuti nella sezione 3, è stata utilizzata la stessa suddivisione nei 5 folds della cross validation).

| | |
|-----------|-------|
| MAE | 0.517 |
| RMSE | 0.575 |
| Precision | 0.034 |
| Recall | 0.260 |

Tabella 5: Risultati evaluation multi-rating RS.

5 Conclusioni

Confrontando i risultati dell’analisi è evidente che l’alta sparsità dei dati influenza negativamente la precisione delle raccomandazioni, ciò avviene sia per gli approcci standard (sezione 3) che per gli approcci che considerano i rating multidimensionali (sezione 4). L’unica soluzione per questo problema, visto che l’esclusione di utenti o ristoranti con pochi rating ridurrebbe troppo il dataset, è la raccolta di un maggior numero di ratings, così da diminuire la percentuale di dati mancanti.

Inoltre, confrontando i risultati degli approcci standard e di quello che considera i ratings multidimensionali, emerge che, nonostante teoricamente la precisione delle raccomandazioni dovrebbe aumentare nel secondo caso, ciò non accade. Questo potrebbe essere causato dall’insufficienza di dati sui fattori qualitativi che influenzano il rating generico: le valutazioni su cibo e servizio non spiegano abbastanza bene la variabilità del rating overall. Una soluzione in questo caso potrebbe essere l’introduzione della valutazione di più fattori qualitativi riguardanti i ristoranti durante la fase di raccolta dei dati, così da aumentare le performance dell’approccio multi-rating.

In generale, un altro metodo per migliorare le prestazioni del recommender system potrebbe essere quello di integrare all’approccio “collaborative filtering” anche quello “content based filtering”, ossia di integrare le informazioni strutturate che abbiamo a disposizione riguardo utenti e ristoranti.

6 Riconoscimenti

Le autrici di questo paper desiderano ringraziare in modo particolare il Professor Markus

Zanker, per la disponibilità e il prezioso aiuto.

- [6] Dietmar Jannach, Markus Zanker, and Matthias Fuchs. Leveraging multi-criteria customer feedback for satisfaction analysis and improved recommendations. *J. of IT & Tourism*, 14(2):119–149, 2014.

Indice

| | | |
|----------|--|----------|
| 1 | Introduzione | 1 |
| 1.1 | Datasets | 1 |
| 2 | Data Exploration | 2 |
| 2.1 | Clusters per coordinate spaziali . | 2 |
| 2.2 | Relative importance of quality domains | 3 |
| 2.3 | Penalty-Reward Contrast Analysis | 3 |
| 3 | Standard Recommender System | 4 |
| 4 | Multi-rating collaborative filtering RS | 5 |
| 5 | Conclusioni | 7 |
| 6 | Riconoscimenti | 7 |

Riferimenti bibliografici

- [1] Kaggle - restaurant data with consumer ratings. <https://www.kaggle.com/uciml/restaurant-data-with-consumer-ratings>.
- [2] Noriaki KANO, Nobuhiko SERAKU, Fumio TAKAHASHI, and Shin ichi TSUJI. Attractive quality and must-be quality. *Journal of the Japanese Society for Quality Control*, 14(2):147–156, 1984-04-15.
- [3] Randall D. Brandt. How service marketers can identify value enhancing service elements. *Journal of Services Marketing*.
- [4] Robin Burke. Recommender systems: An introduction, by dietmar jannach, markus zanker, alexander felfernig, and gerhard friedrich. *International Journal of Human-Computer Interaction*, 28(1):72–73, 2012.
- [5] Panagiotis Symeonidis Ludovik Çoba, Markus Zanker. Rrecsys, r package. <https://cran.r-project.org/package=rrecsys>.